

АННОТАЦИЯ.....	1
ВВЕДЕНИЕ.....	2
1、 ДАННЫЕ И ПРЕДВАРИТЕЛЬНАЯ ОБРАБОТКА.....	3
1.1 Источник данных.....	3
1.2 Очистка данных.....	3
1.3 Предобработка признаков.....	3
2、 ОПИСАТЕЛЬНЫЙ АНАЛИЗ ДАННЫХ.....	5
2.1 Общее распределение статуса занятости.....	5
2.2 Распределение по возрастным группам.....	5
2.3 Распределение по полу.....	5
2.4 Распределение по уровню образования.....	5
2.5 Распределение по отраслям.....	6
2.6 Анализ статистических связей: критерий χ^2	6
3、 МОДЕЛИ ПРОГНОЗИРОВАНИЯ СТАТУСА ЗАНЯТОСТИ.....	8
3.1 Логистическая регрессия.....	8
3.2 Метод опорных векторов (SVM).....	9
3.3 Дерево решений (CART).....	9
3.4 Случайный лес.....	10
4. ОПТИМИЗАЦИЯ МОДЕЛИ И ПРИКЛАДНЫЕ РЕЗУЛЬТАТЫ.....	12
4.1 Источники макроэкономических данных.....	12
4.2 Методология интеграции.....	12
4.3 Результаты расширенной модели.....	12
4.4 Система сопоставления кадров и вакансий.....	13
4.4.1 Архитектура системы.....	13
4.4.2 Признаковое пространство.....	13
4.4.3 Модель DeepFM.....	14
4.5 Сравнительный анализ моделей.....	14
ЗАКЛЮЧЕНИЕ.....	16
СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ.....	18
ПРИЛОЖЕНИЕ А. ПРИМЕРЫ ПРОГРАММНОГО КОДА.....	19
A.1 Загрузка данных и визуализация распределения по возрасту.....	19
A.2 Логистическая регрессия и визуализация коэффициентов.....	19
A.3 Случайный лес и важность признаков.....	19

АННОТАЦИЯ

Настоящий отчет посвящен анализу и прогнозированию состояния занятости населения в регионе Ичан на основе данных обследования 5000 респондентов. После очистки и верификации данных в аналитическую выборку включено 3821 наблюдение, из которых 3118 относятся к занятым и 703 — к безработным. В работе применяются методы описательной статистики, критерий χ^2 Пирсона для анализа связей категориальных признаков со статусом занятости, а также комплекс моделей машинного обучения: логистическая регрессия с L1-регуляризацией, метод опорных векторов (SVM), дерево решений (CART) и случайный лес. Для учета макроэкономического контекста построена модель со смешанными эффектами, включающая внешние показатели (индекс потребительских цен, валовой национальный доход, численность населения и рабочей силы). Дополнительно разработана система сопоставления кадров и вакансий на основе глубокой факторизационной машины (DeerFM). Случайный лес показал наилучшие результаты среди базовых моделей: точность 85.29%, F1-мера 91.63%. После включения макроэкономических переменных точность модели повысилась до 91.5%. Система сопоставления кадров и вакансий достигла точности 98.4% с индексом согласия 0.892.

Ключевые слова: региональный рынок труда; занятость; безработица; машинное обучение; логистическая регрессия; SVM; случайный лес; дерево решений; модель со смешанными эффектами; DeerFM; сопоставление кадров и вакансий.

ВВЕДЕНИЕ

Занятость населения является одним из ключевых индикаторов экономической устойчивости региона и социальной стабильности. В современных условиях углубления отраслевой трансформации, ускоренной цифровизации и изменения требований к квалификации работников точный анализ и прогнозирование состояния занятости приобретают особую актуальность. Особенно остро эти проблемы проявляются на региональном уровне, где различия в промышленной структуре, уровне урбанизации и кадровой политике создают территориально неоднородные рынки труда.

Регион Ичан представляет интерес как пространство, в котором сочетаются индустриальные и сервисные формы занятости, а также происходит постепенное обновление требований к квалификации работников. Настоящая работа основана на эмпирических данных обследования 5000 респондентов в регионе Ичан и направлена на решение следующих задач: (1) количественная оценка распределения статуса занятости по демографическим, образовательным и отраслевым характеристикам; (2) выявление статистически значимых факторов, связанных со статусом занятости; (3) построение и сравнение прогностических моделей классификации на основе методов машинного обучения; (4) оценка влияния макроэкономических показателей на точность прогнозирования; (5) разработка системы сопоставления профилей работников и требований вакансий.

Методологическая основа работы включает описательную статистику, критерии проверки статистических гипотез, линейные и нелинейные модели классификации, ансамблевые алгоритмы и методы глубокого обучения для задач сопоставления. Все вычисления выполнены в среде MATLAB и Python с использованием библиотек scikit-learn, TensorFlow и PyTorch.

1. ДАННЫЕ И ПРЕДВАРИТЕЛЬНАЯ ОБРАБОТКА

1.1 Источник данных

Эмпирической базой исследования послужили обезличенные данные обследования занятости по региону Ичан. Исходный массив включал 5000 наблюдений и содержал 53 переменные, охватывающие демографические характеристики респондентов (возраст, пол, семейное положение, этническая принадлежность), параметры человеческого капитала (уровень образования, профессиональный профиль, специальность), показатели текущего статуса занятости, элементы трудовой биографии и ряд сопутствующих признаков.

1.2 Очистка данных

Подготовка данных включала несколько последовательных этапов. На первом этапе выявлялись пропуски и аномальные значения. Наибольший объем пропусков пришелся на переменную "Специальность" (1146 записей из 5000), что само по себе является информативным: профессиональный профиль часто оказывается зоной неполной фиксации в административных и опросных массивах. Другие переменные с пропусками: "Адрес регистрации" — 3 записи, "Учебное заведение" — 1 запись. Аномальные значения выявлены в переменных: "Адрес регистрации" — 6 записей, "Уровень образования" — 1 запись, "Время трудоустройства" — 1 запись (значение "1905/7/10 0:00" как явно некорректный формат времени), "Учебное заведение" — 10 записей.

На основе предположения о независимости и одинаковой распределенности наблюдений (i.i.d.), а также достаточного объема выборки, записи с пропусками и аномалиями были исключены. После очистки итоговая аналитическая выборка составила 3821 наблюдение, из которых 3118 относятся к занятым и 703 — к безработным. Соотношение классов (приблизительно 4.4:1) указывает на наличие дисбаланса, что учитывалось при настройке алгоритмов классификации.

1.3 Предобработка признаков

Для обеспечения сопоставимости переменных и корректной работы алгоритмов выполнена стандартизация непрерывных признаков по формуле Z-score:

$$z = (x - \mu) / \sigma$$

где μ — среднее значение признака, σ — его стандартное отклонение. Категориальные переменные преобразовывались методом фиктивного (dummy) кодирования. Для проверки мультиколлинеарности применялся коэффициент инфляции дисперсии (VIF), при этом переменные со значением

VIF > 10 исключались из итоговых спецификаций. Целевая переменная определена как бинарный индикатор: значение 1 соответствует статусу занятости, значение 0 — статусу безработицы.

2. ОПИСАТЕЛЬНЫЙ АНАЛИЗ ДАННЫХ

2.1 Общее распределение статуса занятости

Общее распределение статуса занятости в выборке представлено в таблице 2.1. Занятые составляют 81.6% выборки, безработные — 18.4%.

Статус занятости	Количество (чел.)	Доля (%)
Занятые	3118	81.6
Безработные	703	18.4
Всего	3821	100.0

2.2 Распределение по возрастным группам

Распределение респондентов по возрастным группам и статусу занятости представлено в таблице 2.2. Основная масса наблюдений сосредоточена в интервалах 20–30 лет (1838 чел.) и 30–40 лет (1661 чел.). С увеличением возраста наблюдается тенденция к росту доли безработных в группе, однако абсолютные числа в старших возрастных группах невелики, что требует осторожности при интерпретации.

Возрастная группа	Занятые	Безработные	Всего
20–30	1548	290	1838
30–40	1351	310	1661
40–50	169	79	248
50–60	40	24	64
60–70	10	0	10

2.3 Распределение по полу

Соотношение мужчин и женщин в выборке составляет 44.9% к 55.1% соответственно. Распределение статуса занятости по полу показывает, что уровень безработицы среди женщин (20.4%) выше, чем среди мужчин (16.0%).

Пол	Занятые	Безработные	Всего	Доля безработных
Мужской	1443	274	1717	16.0%
Женский	1675	429	2104	20.4%

2.4 Распределение по уровню образования

Распределение по уровню образования показывает, что основную массу занятых составляют респонденты с высшим (бакалавриат — 1453 чел.) и средним профессиональным образованием (1568 чел.). Доля безработных наиболее высока среди лиц со средним профессиональным образованием (20.2%) и в категории "Прочее" (21.7%).

Уровень образования	Занятые	Безработные	Всего	Доля безработных
Магистратура и выше	7	1	8	12.5%
Бакалавриат	1453	276	1729	16.0%
Среднее профессиональное	1568	398	1966	20.2%
Среднее специальное	7	5	12	41.7%
Прочее	83	23	106	21.7%

2.5 Распределение по отраслям

Отраслевая структура занятости демонстрирует высокую концентрацию в категории "Прочие занятые" (3141 чел.), что объясняется особенностями кодирования в исходных данных. Среди идентифицируемых категорий наибольшую численность имеют "Служащие и связанные с ними работники" (256 чел.) и "Специалисты-профессионалы" (71 чел.).

Отрасль / категория занятости	Занятые	Безработные	Всего
Руководители	20	2	22
Специалисты-профессионалы	59	12	71
Служащие и связанные работники	197	59	256
Работники сферы обслуживания	50	9	59
Сельское хозяйство	2	0	2
Производство	42	8	50
Военнослужащие	7	3	10
Прочие занятые	2580	561	3141
Незанятые	156	49	205

2.6 Анализ статистических связей: критерий χ^2

Для проверки статистической связи между категориальными признаками и статусом занятости использовался критерий χ^2 Пирсона. Статистика критерия вычисляется по формуле:

$$\chi^2 = \sum (O_{ij} - E_{ij})^2 / E_{ij}$$

где O_{ij} — наблюдаемая частота в ячейке, E_{ij} — ожидаемая частота при условии независимости, вычисляемая как (сумма по строке $\times$ сумма по столбцу) / общий объем выборки.

Результаты проверки для основных факторов представлены в таблице 2.5. Критическое значение χ^2 при уровне значимости $\alpha = 0.05$ и одной степени свободы составляет 3.841.

Фактор	Значение χ^2	Степени свободы	Критическое значение	Вывод
Пол	12.45	1	3.841	Связь значима ($p < 0.05$)
Возраст	56.93	4	9.488	Связь значима ($p < 0.05$)
Образование	19.41	3	7.815	Связь значима ($p < 0.05$)
Отрасль	12.59	8	15.507	Связь незначима ($p > 0.05$)

Результаты показывают, что пол, возраст и уровень образования статистически значимо связаны со статусом занятости. Это означает, что указанные признаки не могут рассматриваться как нейтральные характеристики и должны быть включены в модели прогнозирования. Отраслевая принадлежность на одномерном уровне не показала статистически значимой связи, что, вероятно, объясняется высокой долей наблюдений в категории "Прочие".

3. МОДЕЛИ ПРОГНОЗИРОВАНИЯ СТАТУСА ЗАНЯТОСТИ

В рамках решения задачи прогнозирования статуса занятости рассмотрены четыре модели классификации: логистическая регрессия, метод опорных векторов (SVM), дерево решений (CART) и случайный лес. Выбор данных моделей обусловлен их различной способностью улавливать линейные и нелинейные зависимости, а также разной степенью интерпретируемости результатов. Для оценки качества моделей использовались следующие метрики: точность (Accuracy), точность положительного прогноза (Precision), полнота (Recall) и F1-мера (F1-score).

3.1 Логистическая регрессия

Логистическая регрессия используется как интерпретируемая базовая модель. Вероятность занятости индивида моделируется через логит-преобразование:

$$P(Y=1|X) = 1 / (1 + \exp(-\beta_0 - \beta_1 X_1 - \beta_2 X_2 - \dots - \beta_k X_k))$$

где Y — статус занятости, X_i — независимые переменные, β_i — коэффициенты регрессии. Модель обучалась с L1-регуляризацией для предотвращения переобучения. Оценка параметров выполнялась методом максимального правдоподобия с использованием биномиального распределения и логит-функции связи.

В модель включены шесть признаков: возраст, пол, этническая принадлежность, семейное положение, уровень образования и специальность. Перед оценкой все непрерывные переменные стандартизированы, категориальные переменные преобразованы в фиктивные. Оценки коэффициентов регрессии представлены в таблице 3.1.

Признак	Коэффициент β	$ \beta $ (норм.)	Уровень влияния
Пол (женский)	-0.3496	0.3496	Первый
Уровень образования	-0.1466	0.1466	Второй
Этническая принадлежность	-0.1150	0.1150	Третий
Семейное положение	-0.0451	0.0451	Четвертый
Возраст	-0.0393	0.0393	Пятый
Специальность	0.0020	0.0020	Шестой

Отрицательный коэффициент при признаке пола (-0.3496) указывает на то, что вероятность занятости для женщин ниже, чем для мужчин (при прочих равных условиях): отношение шансов снижается примерно на 29.3% ($e^{(-0.3496)} - 1 \approx -0.293$). Метрики качества модели на тестовой выборке приведены в таблице 3.2.

Метрика	Значение
Точность (Accuracy)	0.8158
Точность положительного прогноза (Precision)	0.8158
Полнота (Recall)	1.0000
F1-мера (F1-score)	0.8985

3.2 Метод опорных векторов (SVM)

Метод опорных векторов (Support Vector Machine, SVM) строит оптимальную разделяющую гиперплоскость в пространстве признаков, максимизируя зазор между классами. Задача обучения SVM формулируется как задача выпуклой оптимизации:

$$\min (1/2)||w||^2 + C \cdot \sum \xi_i$$

$$\text{при ограничениях: } y_i(w \cdot \varphi(x_i) + b) \geq 1 - \xi_i, \quad \xi_i \geq 0$$

где w — вектор весов, b — смещение, ξ_i — ослабляющие переменные, C — параметр регуляризации, $\varphi(x)$ — функция ядра. В данной работе использовался линейный SVM ($\varphi(x) = x$) со следующими параметрами: ядро — линейное, $C = 1.0$, веса классов — сбалансированные для учета дисбаланса выборки. Результаты классификации представлены в таблице 3.3.

Метрика	Значение
Точность (Accuracy)	0.8158
Точность положительного прогноза (Precision)	0.8158
Полнота (Recall)	1.0000
F1-мера (F1-score)	0.8985

Веса признаков, полученные из линейной SVM-модели, представлены в таблице 3.4. Наибольший вклад вносят признаки пола и уровня образования, что согласуется с результатами логистической регрессии.

Признак	Вес $\times 10^{-5}$	Ранг
Пол	5.9	1
Уровень образования	5.0	2
Возраст	1.8	3
Этническая принадлежность	1.6	4
Специальность	1.4	5
Семейное положение	0.7	6

3.3 Дерево решений (CART)

Дерево решений на основе алгоритма CART (Classification and Regression Tree) выполняет рекурсивное разбиение пространства признаков с использованием критерия минимизации неоднородности. В качестве критерия разбиения используется индекс Джини (Gini impurity):

$$Gini(D) = 1 - \sum p_k^2$$

$$\Delta Gini(D, f, s) = Gini(D) - (|D_{left}|/|D|) \cdot Gini(D_{left}) - (|D_{right}|/|D|) \cdot Gini(D_{right})$$

где p_k — доля наблюдений класса k в узле D , f — признак разбиения, s — пороговое значение, D_{left} и D_{right} — дочерние узлы. Параметры обучения: максимальная глубина дерева — 9, минимальное количество наблюдений для разбиения узла — 20, минимальное количество наблюдений в листе — 5. Результаты классификации приведены в таблице 3.5.

Метрика	Значение
Точность (Accuracy)	0.8231
Полнота (Recall)	0.9963
F1-мера (F1-score)	0.8997

Оценки важности признаков, вычисленные на основе суммарного снижения индекса Джини при разбиениях по каждому признаку, представлены в таблице 3.6. Возраст является доминирующим признаком (вклад 61.5%), что указывает на его высокую прогностическую силу в древовидных структурах.

Признак	Снижение индекса Джини	Относительный вклад
Возраст	0.615	61.5%
Специальность	0.183	18.3%
Уровень образования	0.092	9.2%
Пол	0.068	6.8%
Семейное положение	0.032	3.2%
Этническая принадлежность	0.010	1.0%

3.4 Случайный лес

Случайный лес (Random Forest) представляет собой ансамблевый метод, агрегирующий множество решающих деревьев, каждое из которых обучается на бутстрап-подвыборке данных с использованием случайного подмножества признаков при каждом разбиении. Итоговое решение принимается большинством голосов:

$$\hat{y} = \operatorname{argmax} \sum I(h_t(x) = c)$$

где h_t — t -е дерево, c — класс, I — индикаторная функция. Параметры обучения: количество деревьев $N = 500$, критерий разбиения — индекс Джини, количество случайно отбираемых признаков $m = \sqrt{M}$ (где M — общее количество признаков). Для оценки качества применялась десятикратная кросс-валидация. Результаты представлены в таблице 3.7.

Метрика	Значение	95% доверительный интервал
Точность (Accuracy)	0.8529	[0.812, 0.887]
Точность положительного прогноза (Precision)	0.8547	[0.803, 0.899]

Полнота (Recall)	0.9875	[0.963, 1.000]
F1-мера (F1-score)	0.9163	[0.892, 0.940]

Случайный лес демонстрирует наилучшие показатели среди всех базовых моделей с F1-мерой 91.63%. Оценки важности признаков на основе индекса Джини, усредненные по всем деревьям ансамбля, приведены в таблице 3.8.

Признак	Важность (Gini)	Относительный вклад
Возраст	0.5431	52.4%
Специальность	0.1720	16.6%
Уровень образования	0.0959	9.3%
Пол	0.0674	6.5%
Семейное положение	0.0636	6.1%
Этническая принадлежность	0.0581	5.6%

4. ОПТИМИЗАЦИЯ МОДЕЛИ И ПРИКЛАДНЫЕ РЕЗУЛЬТАТЫ

4.1 Источники макроэкономических данных

Для учета влияния внешней экономической среды на индивидуальную вероятность занятости в модель были дополнительно включены макроэкономические показатели. Источниками послужили данные Национального бюро статистики КНР, статистические ежегодники и отчеты Управления статистики г. Ичан. Перечень включенных показателей представлен в таблице 4.1.

Категория	Показатель	Периодичность
Макроэкономические	Индекс потребительских цен (CPI)	Ежемесячно
Макроэкономические	Валовой национальный доход (GNI)	Ежегодно
Демографические	Численность населения на конец года	Ежегодно
Рынок труда	Численность рабочей силы	Ежеквартально

4.2 Методология интеграции

Интеграция макроэкономических показателей в модель машинного обучения выполнялась методом темпорального согласования: для каждого наблюдения микроданных определялся соответствующий временной период, после чего к индивидуальному вектору признаков присоединялись значения макроэкономических переменных за этот период. Таким образом формировалась расширенная матрица признаков размерности $N \times (M_{ind} + M_{macro})$, где M_{ind} — количество индивидуальных признаков, M_{macro} — количество макроэкономических переменных. Для построения итоговой прогностической модели применялся случайный лес с теми же гиперпараметрами ($N = 500$ деревьев, $m = \sqrt{M}$ признаков на разбиение).

4.3 Результаты расширенной модели

После включения макроэкономических переменных точность модели повысилась до 91.5%, точность положительного прогноза — до 90.1%, полнота — до 91.2%, F1-мера — до 90.6%. Сравнение с базовой моделью случайного леса приведено в таблице 4.2.

Метрика	Базовая модель (RF)	Расширенная модель (RF + макро)	Прирост
Точность (Accuracy)	85.29%	91.5%	+6.21 п.п.
Точность прогноза (Precision)	85.47%	90.1%	+4.63 п.п.
Полнота (Recall)	98.75%	91.2%	−7.55 п.п.

F1-мера (F1-score)	91.63%	90.6%	–1.03 п.п.
--------------------	--------	-------	------------

Оценки важности признаков в расширенной модели представлены в таблице 4.3. Среди макроэкономических переменных наибольшую важность имеют индекс потребительских цен (CPI, важность 0.124) и валовой национальный доход (GNI, важность 0.093). Это свидетельствует о том, что макроэкономическая конъюнктура вносит дополнительный вклад в объяснение вариации статуса занятости, однако индивидуальные характеристики сохраняют доминирующую роль.

Признак	Важность (Gini)	Уровень значимости
Индекс потребительских цен (CPI)	0.1239	★★★★☆
Валовой национальный доход (GNI)	0.0932	★★★★☆
Численность населения	0.0247	★★☆☆☆
Численность рабочей силы	0.0057	★☆☆☆☆

4.4 Система сопоставления кадров и вакансий

4.4.1 Архитектура системы

Одним из прикладных результатов работы является система интеллектуального сопоставления профилей соискателей и требований вакансий. Система построена по двухэтапной архитектуре: (1) этап грубого отбора кандидатов на основе булевых правил фильтрации по обязательным требованиям (уровень образования, отраслевая принадлежность); (2) этап тонкого ранжирования с использованием глубокой факторизационной машины (DeepFM).

4.4.2 Признаковое пространство

Для построения модели сопоставления сформировано многомерное признаковое пространство, включающее: (а) числовые признаки — уровень образования (кодированный по шкале 1–6), разность опыта работы, коэффициент эластичности заработной платы; (б) категориальные признаки — соответствие отрасли, уровень покрытия навыков; (в) пространственные признаки — оценка времени в пути до места работы на основе API геолокации; (г) текстовые признаки — векторные представления описаний вакансий и навыков соискателей на основе BERT с предобучением для китайского языка (BERT-wwm). Для вычисления семантической близости между описанием вакансии и профилем соискателя использовалась косинусная мера сходства:

$$\text{cosine_sim}(A, B) = (A \cdot B) / (||A|| \cdot ||B||)$$

4.4.3 Модель DeepFM

DeepFM (Deep Factorization Machine) объединяет факторизационную машину для моделирования парных взаимодействий признаков низкого порядка и глубокую нейронную сеть для моделирования взаимодействий высокого порядка. Выход модели определяется как:

$$\hat{y} = \sigma(w_{FM} \cdot x + \sum \sum \langle v_i, v_j \rangle x_i x_j + w_{DNN} \cdot h_L)$$

где σ — сигмоидная функция, w_{FM} — линейные веса FM-компоненты, v_i, v_j — векторные представления признаков, h_L — выход последнего скрытого слоя глубокой сети, w_{DNN} — веса выходного слоя.

4.4.4 Результаты сопоставления

Для оценки качества системы использовались метрики точности сопоставления, индекса согласия (fit index), показателя удержания на рабочем месте в течение месяца и времени отклика системы. Результаты сравнения с базовыми методами представлены в таблице 4.4.

Метод	Точность	Индекс согласия	Месячное удержание	Задержка (мс)
Коллаборативная фильтрация	85.6%	0.701	62.3%	248
Глубокая матричная факторизация	91.2%	0.783	68.9%	172
Предлагаемая модель (DeepFM)	98.4%	0.892	81.7%	89

Предлагаемая гибридная модель на основе DeepFM демонстрирует значительное превосходство над традиционными методами: точность сопоставления достигает 98.4% (прирост 41.2% по сравнению с косинусным сходством), индекс согласия составляет 0.892, показатель удержания — 81.7%, а время отклика сокращается до 89 мс благодаря двухэтапной архитектуре фильтрации.

4.5 Сравнительный анализ моделей

Сводные результаты всех рассмотренных моделей прогнозирования статуса занятости представлены в таблице 4.5. Наилучшее качество среди индивидуальных моделей показал случайный лес ($F1 = 91.63\%$), что свидетельствует о наличии существенных нелинейных взаимодействий между признаками. Логистическая регрессия и линейный SVM показали

сопоставимые результаты ($F1 = 89.85\%$), но существенно уступили ансамблевым методам в точности. Дерево решений, несмотря на высокий показатель важности возраста, показало промежуточный результат ($F1 = 89.97\%$).

Модель	Accuracy	Precision	Recall	F1-score
Логистическая регрессия	0.8158	0.8158	1.0000	0.8985
SVM (линейный)	0.8158	0.8158	1.0000	0.8985
Дерево решений (CART)	0.8231	—	0.9963	0.8997
Случайный лес	0.8529	0.8547	0.9875	0.9163
Случайный лес + макро	0.9150	0.9010	0.9120	0.9060

Сравнение важности признаков по всем моделям показывает, что возраст и уровень образования являются стабильно значимыми предикторами во всех спецификациях, в то время как вклад этнической принадлежности и семейного положения варьирует в зависимости от типа модели. Доминирование возраста в древовидных моделях (важность 52–62%) указывает на наличие пороговых эффектов: риск безработицы увеличивается не линейно с возрастом, а скачкообразно в определенных возрастных диапазонах, что может быть связано с устареванием навыков, дискриминацией по возрасту и различиями в мобильности.

ЗАКЛЮЧЕНИЕ

В ходе выполнения работы получены следующие основные результаты:

1. На основе данных обследования 5000 респондентов в регионе Ичан сформирована аналитическая выборка из 3821 наблюдения (3118 занятых, 703 безработных). Проведена комплексная предобработка данных, включающая удаление пропусков и аномалий, стандартизацию непрерывных переменных и фиктивное кодирование категориальных признаков.

2. Описательный анализ выявил значимые различия в статусе занятости по полу, возрасту и уровню образования. Критерий χ^2 Пирсона подтвердил статистическую значимость связи пола ($\chi^2 = 12.45$, $p < 0.05$), возраста ($\chi^2 = 56.93$, $p < 0.05$) и образования ($\chi^2 = 19.41$, $p < 0.05$) со статусом занятости.

3. Среди четырех рассмотренных моделей классификации (логистическая регрессия, SVM, дерево решений, случайный лес) наилучшие результаты показал случайный лес с точностью 85.29% и F1-мерой 91.63%. Во всех моделях возраст и уровень образования стабильно входят в число наиболее значимых предикторов.

4. Включение макроэкономических показателей (CPI, GNI, численность населения, численность рабочей силы) в модель случайного леса позволило повысить точность прогнозирования до 91.5%. Индекс потребительских цен (важность 0.124) и валовой национальный доход (важность 0.093) оказались наиболее значимыми среди макроэкономических переменных, что подтверждает влияние внешней экономической среды на индивидуальные шансы занятости.

5. Разработана двухэтапная система сопоставления кадров и вакансий на основе DeerFM, обеспечивающая точность сопоставления 98.4%, индекс согласия 0.892 и время отклика 89 мс. По всем метрикам система превосходит традиционные методы коллаборативной фильтрации и глубокой матричной факторизации.

6. Полученные результаты могут быть использованы региональными органами управления для: (а) мониторинга уязвимых групп на рынке труда на основе прогностических моделей; (б) проектирования адресных программ переподготовки с учетом выявленных факторов риска; (в) внедрения цифровых сервисов содействия занятости на основе алгоритмов интеллектуального сопоставления кадров и вакансий.

Ограничения работы связаны с кросс-секционным характером данных, не позволяющим делать строгие каузальные выводы, а также с отсутствием в

выборке информации о мягких навыках, мотивации и неформальных каналах поиска работы. Перспективным направлением дальнейших исследований является сочетание количественного анализа с качественными методами и использование панельных данных для отслеживания индивидуальных траекторий занятости во времени.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

1. Becker G. S. Human Capital: A Theoretical and Empirical Analysis, with Special Reference to Education. 3rd ed. Chicago: University of Chicago Press, 1993.
2. Breiman L. Random Forests // Machine Learning. 2001. Vol. 45, No. 1. P. 5–32.
3. Cortes C., Vapnik V. Support-Vector Networks // Machine Learning. 1995. Vol. 20, No. 3. P. 273–297.
4. Guo H., Tang R., Ye Y., Li Z., He X. DeepFM: A Factorization-Machine Based Neural Network for CTR Prediction // Proceedings of the 26th International Joint Conference on Artificial Intelligence. 2017. P. 1725–1731.
5. Lundberg S. M., Lee S.-I. A Unified Approach to Interpreting Model Predictions // Advances in Neural Information Processing Systems. 2017. Vol. 30.
6. Mortensen D. T., Pissarides C. A. Job Creation and Job Destruction in the Theory of Unemployment // Review of Economic Studies. 1994. Vol. 61, No. 3. P. 397–415.
7. Pinheiro J. C., Bates D. M. Mixed-Effects Models in S and S-PLUS. New York: Springer, 2000.
8. Athey S., Imbens G. W. Machine Learning Methods That Economists Should Know About // Annual Review of Economics. 2019. Vol. 11. P. 685–725.
9. Национальное бюро статистики Китая. Статистическое коммюнике о социально-экономическом развитии Китая за 2024 год.
10. Ежегодник статистики Китая 2025.
11. Статистическое коммюнике о социально-экономическом развитии города Ичан за 2024 год.
12. Цзян Цююань, Сэ Цзинсинь, Е Цзюнь. Математическое моделирование. 4-е изд. Пекин: Издательство высшего образования, 2011.

ПРИЛОЖЕНИЕ А. ПРИМЕРЫ ПРОГРАММНОГО КОДА

А.1 Загрузка данных и визуализация распределения по возрасту

```
% Чтение данных
data = readtable('employment_data.xlsx', 'Sheet', 'данные');

% Извлечение возраста и статуса занятости
cancel_col = strtrim(string(data.c_acc028));
is_employed = ~(cancel_col == "\N");
employment_status = repmat("Unemployed", height(data), 1);
employment_status(is_employed) = "Employed";
age = data.age;

% Удаление пропусков
valid_rows = ~ismissing(age);
age_clean = age(valid_rows);
status_clean = employment_status(valid_rows);

% Визуализация: boxplot возраста по статусу занятости
figure;
boxplot(age_clean, status_clean);
xlabel('Employment Status');
ylabel('Age');
title('Age Distribution by Employment Status');
```

А.2 Логистическая регрессия и визуализация коэффициентов

```
% Признаки и коэффициенты логистической регрессии
features = {'Major', 'Age', 'MaritalStatus', 'Ethnicity', 'CulturalLevel', 'Gender'};
coeffs = [0.002041, -0.039272, -0.045125, -0.114960, -0.146593, -0.349620];

% Сортировка по абсолютному значению
[~, sortIdx] = sort(abs(coeffs), 'descend');
sortedFeatures = features(sortIdx);
sortedCoeffs = coeffs(sortIdx);

% Визуализация
figure('Position', [100 100 800 400]);
hold on;
posIdx = sortedCoeffs > 0;
negIdx = sortedCoeffs <= 0;
barh(categorical(sortedFeatures(posIdx)), sortedCoeffs(posIdx),...
     'FaceColor', [0.2 0.6 0.8], 'BarWidth', 0.6);
barh(categorical(sortedFeatures(negIdx)), sortedCoeffs(negIdx),...
     'FaceColor', [0.8 0.3 0.2], 'BarWidth', 0.6);
grid on;
xlabel('Коэффициент регрессии', 'FontSize', 12, 'FontWeight', 'bold');
title('Важность признаков: логистическая регрессия', 'FontSize', 14, 'FontWeight', 'bold');
xline(0, '--k', 'LineWidth', 1.2);
legend({'Положительное влияние', 'Отрицательное влияние'}, 'Location', 'southeast');
```

А.3 Случайный лес и важность признаков

```
% Важность признаков случайного леса (Gini importance)
features = {'Age', 'Major', 'CulturalLevel', 'Gender', 'MaritalStatus', 'Ethnicity'};
```

```

importance = [0.543081, 0.171977, 0.095917, 0.067382, 0.063566, 0.058077];

% Сортировка
[vals, idx] = sort(importance, 'descend');
sortedFeatures = features(idx);
sortedImportance = vals;

% Визуализация
figure('Position', [200 200 750 400]);
barh(categorical(sortedFeatures), sortedImportance,...
    'FaceColor', [0.44 0.23 0.7], 'BarWidth', 0.7);
xlim([0 ceil(max(sortedImportance)*10)/10 + 0.05]);
grid on;
xlabel('Важность признака (Gini)', 'FontSize', 13, 'FontWeight', 'bold');
title('Важность признаков: случайный лес', 'FontSize', 15, 'FontWeight', 'bold');

% Добавление числовых меток
textOffset = 0.015;
for i = 1:length(sortedImportance)
    text(sortedImportance(i) + textOffset, i,...
        sprintf('%.4f', sortedImportance(i)),...
        'FontSize', 11, 'VerticalAlignment', 'middle');
end

```